


Introdução à análise de redes Bayesianas

Estrutura:

1. Introdução
- 2. Conceitos básicos**
3. Estimação de parâmetros e inferência
4. Construção de redes Bayesianas orientadas por dados


Rede bayesiana: conceitos básicos

- Modelo probabilístico
- Composto por variáveis aleatórias e dependências condicionais entre elas, as quais envolvem parâmetros.
- As dependências condicionais não podem formar ciclos.
- Representado por um grafo acíclico direcionado (DAG).




Rede bayesiana: conceitos básicos


- Modelo probabilístico
- Composto por variáveis aleatórias e dependências condicionais entre elas, as quais envolvem parâmetros.
- As dependências condicionais não podem formar ciclos.
- Representado por um grafo acíclico direcionado (DAG).
- Limitações: análogas aos outros modelos estatísticos (ex. variáveis confundidoras não observadas)



Rede bayesiana: probabilidade condicional




Rede bayesiana: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296


Rede bayesiana: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$

Rede bayesiana: probabilidade condicional




		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{296 / (2451 + 2219 + 34 + 296)}{(296 + 2219) / (2451 + 2219 + 34 + 296)}$$

Rede bayesiana: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296


$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{296 / (2451 + 2219 + 34 + 296)}{(296 + 2219) / (2451 + 2219 + 34 + 296)}$$

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{296}{(296 + 2219)} = \mathbf{0.1177}$$

Rede bayesiana: construção

- Pode ser criada:
 - **Manualmente** (com base apenas no conhecimento prévio)
 - **A partir de dados** (incluindo também o conhecimento prévio).



Linguagem de programação R

Variáveis: É um local de armazenamento nomeado para dados

- `a <- "Oi"`
- `a = "Oi"`
- `b = 1`
- `x = c(1,2,3,4)`



Linguagem de programação R

Variáveis: É um local de armazenamento nomeado para dados

- `a <- "Oi"`
- `a = "Oi"`
- `b = 1`
- `x = c(1,2,3,4)`

Funções: É um bloco de código para executar uma tarefa específica (ex. realizar um cálculo, criar um gráfico, modificar uma variável)

- `mean(x)`
- `plot(dag)`



Rede bayesiana: pacotes de R

Pacotes:

- **bnlearn**: an R package for Bayesian network learning and inference (Scutari 2010)
- **deal**: Learning Bayesian Networks with Mixed Variables (Bøttcher et al. 2003)
- **pcalg**: Methods for Graphical Models and Causal Inference (Kalisch et al. 2012)

Referencias:

Bøttcher, S. G., & Dethlefsen, C. (2003). deal: A package for learning Bayesian networks. Journal of statistical software, 8, 1-40.

Kalisch, M., Mächler, M., Colombo, D., Maathuis, M. H., & Bühlmann, P. (2012). Causal inference using graphical models with the R package pcalg. Journal of statistical software, 47, 1-26.

Scutari, M. (2010). Learning Bayesian networks with the bnlearn R package. Journal of statistical software, 35, 1-22.

Rede bayesiana: instalação

Executar as linhas de comando:

```
if(!require("bnlearn"))  
  install.packages('bnlearn', dependencies=T)  
  
if(!require("Rgraphviz")) {  
  if (!require("BiocManager", quietly = TRUE))  
    install.packages("BiocManager")  
  
  BiocManager::install("Rgraphviz")  
}
```

Rede bayesiana: carregar pacotes

Executar as linhas de comando:

```
library(bnlearn)  
library(Rgraphviz)
```

```
set.seed(1243661)  
data(asia)
```

Rede bayesiana: dados de exemplo

- Banco de dados construído por Lauritzen e Spiegelhalter (1988), incluído no pacote *bnlearn*
- Dados fictícios
- Fatores de risco e de diagnóstico de doenças pulmonares (tuberculose, câncer de pulmão ou bronquite).
- Variáveis (dicotômicas, sim/não):
 - A (viagem para uma zona endêmica de tuberculose)
 - S (tabagismo)
 - T (tuberculose)
 - L (câncer de pulmão)
 - B (bronquite)
 - E (tuberculose versus câncer de pulmão/bronquite)
 - D (dispneia)
 - X (radiografia de tórax)
- Executar:
 - `summary(asia)`

J. R. Statist. Soc. B (1988)
50, No. 2, pp. 157-224

Local Computations with Probabilities on Graphical Structures and their Application to Expert Systems

By S. L. LAURITZEN

and

D. J. SPIEGELHALTER†

Aalborg University, Denmark

MRC Biostatistics Unit, Cambridge, UK

[Read before the Royal Statistical Society at a meeting organised by the Research Section on Wednesday, January 13th, 1988, Professor A. P. Dawid in the Chair]

SUMMARY

A causal network is used in a number of areas as a depiction of patterns of 'influence' among sets of variables. In expert systems it is common to perform 'inference' by means of local computations on such large but sparse networks. In general, non-probabilistic methods are used to handle uncertainty when propagating the effects of evidence, and it has appeared that exact probabilistic methods are not computationally feasible. Motivated by an application in electromyography, we counter this claim by exploiting a range of local representations for the joint probability distribution, combined with topological changes to the original network termed 'marrying' and 'filling-in'. The resulting structure allows efficient algorithms for transfer between representations, providing rapid absorption and propagation of evidence. The scheme is first illustrated on a small, fictitious but challenging example, and the underlying theory and computational aspects are then discussed.

Keywords: ARTIFICIAL INTELLIGENCE; BAYESIAN METHODS; CAUSAL MARKOV RANDOM FIELD; DECOMPOSABLE GRAPHS; EXPERT SYSTEMS; LOCAL POTENTIALS; MARKOV RANDOM FIELD; MAXIMUM CARDINALITY SEARCH; PROBABILISTIC REASONING; TRIANGULATED GRAPHS


Rede bayesiana: construção

Executar as linhas de comando:

```
variaveis = c("D","T","L","B","A","S","X","E")  
e = empty.graph(variaveis)
```


```
e = set.arc(e, "A","T")  
e = set.arc(e, "T","E")  
e = set.arc(e, "E","X")  
e = set.arc(e, "S","L")  
e = set.arc(e, "S","B")  
e = set.arc(e, "L","E")  
e = set.arc(e, "E","D")  
e = set.arc(e, "B","D")
```

```
graphviz.plot(e, layout = "dot")  
e$arcs
```




Rede bayesiana: controlar ciclos

- O grafo é acíclico?
 - Executar: `acyclic(e)`




Rede bayesiana: nós

- Os nós raiz são os que não recebem nenhuma dependência condicional (aresta).
- Os nós folha são aqueles que não possuem dependências desde eles.
- Identificar nós raiz e folha do grafo
- Comandos:
 - `root.nodes(e)`
 - `leaf.nodes(e)`




Rede bayesiana: nós

- Quais são os nós descendentes do nó A?
 - executar: `children(e, "A")`
- Quais são os nós ascendentes do nó E?
 - executar: `parents(e, "E")`



Rede bayesiana: estruturas “V”

- Identificar as estruturas em forma de “V” no grafo.
 - executar: `vstructs(e)`



Rede bayesiana: d-separação (separação direcionada)

- Uma separação gráfica implica uma independência probabilística

Rede bayesiana: d-separação (separação direcionada)


- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.




X e Y são independentes

Rede bayesiana: d-separação (separação dirigida)

- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.



X e Y são independentes



X e Y são condicionalmente independentes, se Z for conhecido

Rede bayesiana: d-separação (separação dirigida)


- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.

$$P(x,z,y) = P(x)P(z|x)P(y|z)$$


$$P(y|x,z) = P(x,z,y) / P(x,z)$$

$$P(y|x,z) = P(x)P(z|x)P(y|z) / P(x)P(z|x)$$

$$P(y|x,z) = P(y|z)$$




X e Y são independentes




X e Y são condicionalmente independentes, se Z for conhecido

Rede bayesiana: d-separação (separação dirigida)


- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.
- Se Z é uma causa comum de X e Y, então X e Y são condicionalmente independentes dado Z.



X e Y são independentes



X e Y são condicionalmente independentes, se Z for conhecido



X e Y são condicionalmente independentes, se Z for conhecido

Rede bayesiana: d-separação (separação dirigida)


- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.
- Se Z é uma causa comum de X e Y, então X e Y são condicionalmente independentes dado Z.

$$P(x,y,z) = P(z)P(x|z)P(y|z)$$


$$P(x|y,z) = P(x,y,z) / P(y,z)$$

$$P(x|y,z) = P(z)P(x|z)P(y|z) / P(z)P(y|z)$$


$$P(x|y,z) = P(x|z)$$



X e Y são independentes



X e Y são condicionalmente independentes, se Z for conhecido




X e Y são condicionalmente independentes, se Z for conhecido

Rede bayesiana: d-separação (separação dirigida)


- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.
- Se Z é uma causa comum de X e Y, então X e Y são condicionalmente independentes dado Z.




X e Y são independentes



X e Y são condicionalmente independentes, se Z for conhecido







X e Y são condicionalmente independentes, se Z for conhecido



X e Y são independentes. Mas não são condicionalmente independentes dado Z.


Rede bayesiana: d-separação (separação dirigida)

- Uma separação gráfica implica uma independência probabilística
- Se todos os caminhos entre X e Y estão bloqueados, então X e Y são independentes.
- Se Z está no caminho entre X e Y, então X e Y são condicionalmente independentes dado Z.
- Se Z é uma causa comum de X e Y, então X e Y são condicionalmente independentes dado Z.




Rede bayesiana: d-separação (exemplos)

- S e A são independentes?
executar: `dsep(e, "S", "A")`
- S e E são independentes?
executar: `dsep(e, "S", "E")`
- S e E são independentes, dado L?
executar: `dsep(e, "S", "E", "L")`
- B e L são independentes, dado S?
executar: `dsep(e, "B", "L", "S")`




Rede bayesiana: cobertura de Markov

- A cobertura de Markov de um nó é o conjunto que contém os “pais”, “filhos” e “co-pais” (outros pais dos filhos) do nó.




Rede bayesiana: cobertura de Markov

- A cobertura de Markov de um nó é o conjunto que contém os “pais”, “filhos” e “co-pais” (outros pais dos filhos) do nó.
- Um nó é condicionalmente independente de todos os outros nós do grafo, dado sua cobertura de Markov.



Rede bayesiana: cobertura de Markov

- A cobertura de Markov de um nó é o conjunto que contém os “pais”, “filhos” e “co-pais” (outros pais dos filhos) do nó.
- Um nó é condicionalmente independente de todos os outros nós do grafo, dado sua cobertura de Markov.
- Isso quer dizer que para conhecer o estado do nó A , apenas seria necessário conhecer o estado dos nós da sua cobertura de Markov.



Rede bayesiana: cobertura de Markov (exemplos)

- Qual é a cobertura de Markov de L?
executar: `mb(e, node = "L")`
- Qual é a cobertura de Markov de E?
executar: `mb(e, node = "E")`

