


Introdução à análise de redes Bayesianas

Estrutura:


1. Introdução
2. Conceitos básicos
- 3. Estimação de parâmetros e inferência**
4. Construção de redes Bayesianas orientadas por dados

Rede bayesiana: estimação de parâmetros

- Modelo probabilístico
- Composto por variáveis aleatórias e dependências condicionais entre elas, **as quais envolvem parâmetros.**
- As dependências condicionais não podem formar ciclos.
- Representado por um grafo acíclico direcionado (DAG).




Estimação de parâmetros: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$

Estimação de parâmetros: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296


$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{não})$$

$$P(\text{Câncer de pulmão} = \mathbf{não} \mid \text{Tabagismo} = \mathbf{não})$$

$$P(\text{Câncer de pulmão} = \mathbf{não} \mid \text{Tabagismo} = \mathbf{sim})$$

Estimação de parâmetros: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{sim}) = \frac{P(\text{Câncer de pulmão} = \mathbf{sim}, \text{Tabagismo} = \mathbf{sim})}{P(\text{Tabagismo} = \mathbf{sim})}$$


$$P(\text{Câncer de pulmão} = \mathbf{sim} \mid \text{Tabagismo} = \mathbf{não})$$

$$P(\text{Câncer de pulmão} = \mathbf{não} \mid \text{Tabagismo} = \mathbf{não})$$

$$P(\text{Câncer de pulmão} = \mathbf{não} \mid \text{Tabagismo} = \mathbf{sim})$$

		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	0.9863	0.8823
	Sim	0.0137	0.1177

Estimação de parâmetros: probabilidade condicional




		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$P(\text{Câncer de pulmão} \mid \text{Tabagismo})$

		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	0.9863	0.8823
	Sim	0.0137	0.1177

Estimação de parâmetros: probabilidade condicional



		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	2451	2219
	Sim	34	296

$$P(\text{Tabagismo} = \text{sim}) = (2219 + 296) / (2451 + 2219 + 34 + 296)$$

$$P(\text{Tabagismo} = \text{não}) = (2451 + 34) / (2451 + 2219 + 34 + 296)$$

P(Tabagismo)

Tabagismo	
Não	Sim
0.4970	0.5030

P(Câncer de pulmão | Tabagismo)

		Tabagismo	
		Não	Sim
Câncer de pulmão	Não	0.9863	0.8823
	Sim	0.0137	0.1177

Estimação de parâmetros

Executar:

```
fit = bn.fit(e, asia, method = "mle")
```

```
fit
```


Estimação de parâmetros

Executar:

```
fit = bn.fit(e, asia, method = "mle")
```

```
fit
```

```
Parameters of node S (multinomial distribution)
Conditional probability table:
      no   yes
0.497 0.503
```

```
Parameters of node L (multinomial distribution)
Conditional probability table:
      S
L      no      yes
no 0.98631791 0.88230616
yes 0.01368209 0.11769384
```

Estimação de parâmetros

Executar:

```
fit = bn.fit(e, asia, method = "mle")
```

```
fit
```

```
graphviz.chart(fit, type = "barprob")
```

Parameters of node S (multinomial distribution)


Conditional probability table:

	no	yes
	0.497	0.503

Parameters of node L (multinomial distribution)

Conditional probability table:

	S	
L	no	yes
no	0.98631791	0.88230616
yes	0.01368209	0.11769384



Estimação de parâmetros

- O método usado é conhecido como: **estimador de máxima verossimilhança** (mle)
- Outro método: **estimador Bayesiano posterior** (pode permitir a inclusão de conhecimento prévio sobre os parâmetros)

Ajuste / desempenho do modelo: BIC


- Critério BIC:

$$\text{BIC} = \sum_{i=1}^n \log P_{X_i}(X_i | \Pi_{X_i}) - \frac{d}{2} \log n$$

- Executar: `score(e, asia, type = "bic")`

Ajuste / desempenho do modelo: Erro de classificação

- Validação cruzada



- Executar:

```
cvA = bn.cv(asia, bn = e, k = 10, fit = "mle", loss="pred", loss.args = list(target = "X"))  
loss(cvA)
```

Inferência

- **Objetivo:** estimar a probabilidade de um evento X dada a evidência Y [$P(X=x \mid Y=y)$]

Inferência

- **Objetivo:** estimar a probabilidade de um evento X dada a evidência Y [$P(X=x \mid Y=y)$]
- Abordagens:
 - Inferência exata:
 - Calcular a probabilidade exata a partir da resolução da integral
 - Elevado custo computacional, apenas é viável para redes pequenas

Inferência

- **Objetivo:** estimar a probabilidade de um evento X dada a evidência Y [$P(X=x \mid Y=y)$]
- Abordagens:
 - Inferência exata:
 - Calcular a probabilidade exata a partir de resolução da integral
 - Elevado custo computacional, apenas é viável para redes pequenas
 - Inferência aproximada:
 - Baseada em simulações de Monte Carlo
 - Gerar observações aleatórias a partir da rede bayesiana
 - Usar essas observações para calcular estimativas aproximadas das probabilidades condicionais que nos interessam.


Inferência aproximada: Logic sampling (Amostragem lógica)

- Duas etapas:
 1. Gerar observações aleatórias a partir da rede bayesiana
 2. Usar essas observações para calcular estimativas aproximadas das probabilidades condicionais que nos interessam.

Algorithm 4.2 Logic Sampling Algorithm

1. Order the variables in $\mathbf{X}$ according to the topological ordering implied by G , say $X_{(1)} \prec X_{(2)} \prec \dots \prec X_{(p)}$.
 2. For a suitably large number of samples $\mathbf{x}^* = (x_1^*, \dots, x_p^*)$:
 - a. for $i = 1, \dots, p$, generate $x_{(i)}^*$ from $X_{(i)} \mid \Pi_{X_{(i)}}$;
 - b. if $\mathbf{x}$ includes $\mathbf{E}$, set $n_{\mathbf{E}} = n_{\mathbf{E}} + 1$;
 - c. if $\mathbf{x}$ includes both $\mathbf{Q} = \mathbf{q}$ and $\mathbf{E}$, set $n_{\mathbf{E}, \mathbf{q}} = n_{\mathbf{E}, \mathbf{q}} + 1$.
 3. Estimate $P(\mathbf{Q} \mid \mathbf{E}, G, \Theta)$ with $n_{\mathbf{E}, \mathbf{q}} / n_{\mathbf{E}}$.
-

Inferência aproximada: Logic sampling, exemplo (etapa 1)



Dados resultantes:

#	S	A	B	L	T	D	E	X
1								
2								
...								
n								


Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1								
2								
...								
n								




Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1								
2								
...								
n								




Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1								
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)


Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45

Dados resultantes:

#	S	A	B	L	T	D	E	X
1								
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**


Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim							
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45


Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim							
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45


Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim							
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45


Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim							
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**


Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório $[0, 1]$: 0.20

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim							
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**


Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório $[0, 1]$: 0.20

Regra: $0.20 < 0.1177$? (não), então **L = não**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim			não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório $[0, 1]$: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório $[0, 1]$: 0.20


Regra: $0.20 < 0.1177$? (não), então **L = não**

Nó: **B**

Informação no modelo: $P(B=\text{sim} \mid S = \text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim			não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório [0, 1]: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório [0, 1]: 0.20


Regra: $0.20 < 0.1177$? (não), então **L = não**

Nó: **B**

Informação no modelo: $P(B=\text{sim} \mid S = \text{sim})$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim			não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório [0, 1]: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório [0, 1]: 0.20


Regra: $0.20 < 0.1177$? (não), então **L = não**

Nó: **B**

Informação no modelo: $P(B=\text{sim} \mid S = \text{sim}) = 0.7177$

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim			não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório [0, 1]: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório [0, 1]: 0.20

Regra: $0.20 < 0.1177$? (não), então **L = não**


Nó: **B**

Informação no modelo: $P(B=\text{sim} \mid S = \text{sim}) = 0.7177$

Número aleatório [0, 1]: 0.30

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim			não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **S**

Informação no modelo: $P(S=\text{sim}) = 0.503$

Número aleatório [0, 1]: 0.45

Regra: $0.45 < 0.503$? (sim), então **S = sim**

Nó: **L**

Informação no modelo: $P(L=\text{sim} \mid S = \text{sim}) = 0.1177$

Número aleatório [0, 1]: 0.20

Regra: $0.20 < 0.1177$? (não), então **L = não**

Nó: **B**


Informação no modelo: $P(B=\text{sim} \mid S = \text{sim}) = 0.7177$

Número aleatório [0, 1]: 0.30

Regra: $0.30 < 0.7177$? (sim), então **B = sim**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim		sim	não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **A**


Informação no modelo: $P(A=\text{sim}) = 0.008$

Número aleatório $[0, 1]$: 0.16

Regra: $0.16 < 0.008$? (não), então **A = não**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não				
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **A**

Informação no modelo: $P(A=\text{sim}) = 0.008$

Número aleatório [0, 1]: 0.16

Regra: $0.16 < 0.008$? (não), então **A = não**

Nó: **T**


Informação no modelo: $P(T=\text{sim} \mid A=\text{não}) = 0.048$

Número aleatório [0, 1]: 0.87

Regra: $0.87 < 0.048$? (não), então **T = não**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não	não			
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **A**

Informação no modelo: $P(A=\text{sim}) = 0.008$

Número aleatório [0, 1]: 0.16

Regra: $0.16 < 0.008$? (não), então **A = não**

Nó: **T**

Informação no modelo: $P(T=\text{sim} \mid A=\text{não}) = 0.048$

Número aleatório [0, 1]: 0.87

Regra: $0.87 < 0.048$? (não), então **T = não**

Nó: **E**


Informação no modelo: $P(E=\text{sim} \mid (T=\text{não} \text{ e } L=\text{não})) = 0.000$

Número aleatório [0, 1]: 0.23

Regra: $0.23 < 0.000$? (não), então **E = não**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não	não		não	
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **X**


Informação no modelo: $P(X=\text{sim} \mid E=\text{não}) = 0.043$

Número aleatório $[0, 1]$: 0.01

Regra: $0.01 < 0.043$? (sim), então **X = sim**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não	não		não	sim
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **X**

Informação no modelo: $P(X=\text{sim} \mid E=\text{não}) = 0.043$

Número aleatório $[0, 1]$: 0.01

Regra: $0.01 < 0.043$? (sim), então **X = sim**

Nó: **D**


Informação no modelo: $P(D=\text{sim} \mid (B=\text{sim} \text{ e } E=\text{não})) = 0.786$

Número aleatório $[0, 1]$: 0.64

Regra: $0.64 < 0.786$? (sim), então **D = sim**

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não	não	sim	não	sim
2								
...								
n								



Inferência aproximada: Logic sampling, exemplo (etapa 1)

Nó: **X**

Informação no modelo: $P(X=\text{sim} \mid E=\text{não}) = 0.043$

Número aleatório $[0, 1]$: 0.01

Regra: $0.01 < 0.043$? (sim), então **X = sim**

Nó: **D**

Informação no modelo: $P(D=\text{sim} \mid (B=\text{sim} \text{ e } E=\text{não})) = 0.786$


Número aleatório $[0, 1]$: 0.64

Regra: $0.64 < 0.786$? (sim), então **D = sim**

...
...
...

Dados resultantes:

#	S	A	B	L	T	D	E	X
1	sim	não	sim	não	não	sim	não	sim
2	não	sim	não	sim	sim	sim	sim	sim
...	...	...	...	...	...	...	...	...
n	...	...	...	...	...	...	...	...




Inferência aproximada: Logic sampling, exemplo (etapa 1)

Executar:

```
rFit = rbn(fit,100000)
head(rFit,5)
```

	D	T	L	B	A	S	X	E
1	no	no	no	no	no	no	no	no
2	no	no	no	no	no	yes	no	no
3	no	no	no	no	no	no	no	no
4	no	no	no	no	no	yes	no	no
5	yes	no	no	yes	no	no	no	no



Inferência aproximada: Logic sampling (Amostragem lógica)


- Duas etapas:
 1. Gerar observações aleatórias a partir da rede bayesiana
 2. Usar essas observações para calcular estimativas aproximadas das probabilidades condicionais que nos interessam.

Algorithm 4.2 Logic Sampling Algorithm

1. Order the variables in $\mathbf{X}$ according to the topological ordering implied by G , say $X_{(1)} \prec X_{(2)} \prec \dots \prec X_{(p)}$.
 2. For a suitably large number of samples $\mathbf{x}^* = (x_1^*, \dots, x_p^*)$:
 - a. for $i = 1, \dots, p$, generate $x_{(i)}^*$ from $X_{(i)} \mid \Pi_{X_{(i)}}$;
 - b. if $\mathbf{x}$ includes $\mathbf{E}$, set $n_{\mathbf{E}} = n_{\mathbf{E}} + 1$;
 - c. if $\mathbf{x}$ includes both $\mathbf{Q} = \mathbf{q}$ and $\mathbf{E}$, set $n_{\mathbf{E}, \mathbf{q}} = n_{\mathbf{E}, \mathbf{q}} + 1$.
 3. Estimate $P(\mathbf{Q} \mid \mathbf{E}, G, \Theta)$ with $n_{\mathbf{E}, \mathbf{q}} / n_{\mathbf{E}}$.
-

Inferência aproximada: Logic sampling, exemplo (etapa 2)


Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?



Inferência aproximada: Logic sampling, exemplo (etapa 2)

Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?

$$P(L = \text{sim} \mid S = \text{sim}) = \frac{P(L = \text{sim}, S = \text{sim})}{P(S = \text{sim})}$$



Inferência aproximada: Logic sampling, exemplo (etapa 2)

Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?


$$P(L = \text{sim} \mid S = \text{sim}) = \frac{P(L = \text{sim}, S = \text{sim})}{P(S = \text{sim})}$$

Executar:

```
rFit = rbn(fit,100000)
```

```
head(rFit,5)
```

```
table(rFit[,c("L", "S")])
```



Inferência aproximada: Logic sampling, exemplo (etapa 2)

Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?

$$P(L = \text{sim} \mid S = \text{sim}) = \frac{P(L = \text{sim}, S = \text{sim})}{P(S = \text{sim})}$$


Executar:

```
rFit = rbn(fit,100000)
```

```
head(rFit,5)
```

```
table(rFit[,c("L", "S")])
```

		S	
L		no	yes
		49107	44396
	no	684	5813
	yes		



Inferência aproximada: Logic sampling, exemplo (etapa 2)

Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?

$$P(L = \text{sim} \mid S = \text{sim}) = \frac{P(L = \text{sim}, S = \text{sim})}{P(S = \text{sim})}$$


Executar:

```
rFit = rbn(fit,100000)
head(rFit,5)
```

```
table(rFit[,c("L", "S")])
```

		S	
L		no	yes
		49107	44396
	no	49107	44396
	yes	684	5813

$$P(L = \text{sim} \mid S = \text{sim}) = \frac{5813}{5813 + 44396} = 0.1158$$



Inferência aproximada: Logic sampling, exemplo


Qual é a probabilidade de ter câncer de pulmão (L=sim) se fumou (S=sim)?

$$P(L = \text{sim} \mid S = \text{sim}) = \frac{P(L = \text{sim}, S = \text{sim})}{P(S = \text{sim})}$$

Executar:

```
cpquery(fit, event = (L == "yes"), evidence = (S == "yes"), n=10000000)
```

~0.1157761



Inferência aproximada: mais exemplos

Executar:

```
cpquery(fit, event = (L == "yes"), evidence = (S == "yes") | (S == "no"), n=10000000)
```

```
cpquery(fit, event = (X == "yes"), evidence = ((T == "yes") & (S == "yes")), n=10000000)
```

```
cpquery(fit, event = (X == "yes"), evidence = ((T == "no") & (S == "yes")), n=10000000)
```


Inferência aproximada: mais exemplos (2)

Executar:

```
sim_sim = cpquery(fit, event = (L == "yes"), evidence = (S == "yes"), n=10000000)
sim_nao = cpquery(fit, event = (L == "yes"), evidence = (S == "no"), n=10000000)
nao_nao = cpquery(fit, event = (L == "no"), evidence = (S == "no"), n=10000000)
nao_sim = cpquery(fit, event = (L == "no"), evidence = (S == "yes"), n=10000000)

(sim_sim / nao_sim) / (sim_nao / nao_nao)
```

Inferência aproximada: mais exemplos (2)

Executar:

```
sim_sim = cpquery(fit, event = (L == "yes"), evidence = (S == "yes"), n=10000000)
sim_nao = cpquery(fit, event = (L == "yes"), evidence = (S == "no"), n=10000000)
nao_nao = cpquery(fit, event = (L == "no"), evidence = (S == "no"), n=10000000)
nao_sim = cpquery(fit, event = (L == "no"), evidence = (S == "yes"), n=10000000)
```

```
(sim_sim / nao_sim) / (sim_nao / nao_nao)
```

```
fitGLM = glm(L ~ S, data=asia,family=binomial())
summary(fitGLM)
```

```
exp(coef(fitGLM))[2]
```

Inferência aproximada: Logic sampling, limitação e outros

Limitação de logic sampling:

- Se a evidência tiver uma probabilidade pequena (ex. <0.001), a aproximação não é boa. Já que poucas observações vão cumprir com a evidência.

Inferência aproximada: Logic sampling, limitação e outros

Limitação de logic sampling:

- Se a evidência tiver uma probabilidade pequena (ex. <0.001), a aproximação não é boa. Já que poucas observações vão cumprir com a evidência.

Outros métodos de inferência aproximada:

- Likelihood Weighting Algorithm
- Adaptive importance sampling (AIS-BN)
- Evidence pre-propagation importance sampling (EPIS-BN)